

Salir a la pizarra: un modelo de monitoreo docente bajo IA generativa

Joaquín Martínez *

Otoño 2026

Resumen

Modelo la interacción entre un profesor y sus estudiantes en un contexto donde se le pueden delegar entregables académicos a la IA generativa en desmedro del aprendizaje. Posterior a la entrega de la tarea el profesor elige una probabilidad de monitoreo, instrumentada como presentación aleatoria en clase, que es costosa en tiempo para el profesor. El estudiante, observando ese nivel de monitoreo, decide cómo dividir la producción de su tarea entre esfuerzo propio, que genera aprendizaje, y delegación a la IA, que solo genera nota. Bajo supuestos estándar de costos cuadráticos y una tecnología de aprendizaje lineal, el modelo admite solución cerrada y entrega predicciones de estática comparativa testeables sobre los determinantes del monitoreo óptimo. La principal implicancia normativa es que el monitoreo debe diseñarse como dispositivo pedagógico antes que como castigo. La severidad de la exposición pública disuade la delegación a la IA pero no aumenta el aprendizaje, mientras que la productividad del mecanismo, entendida como su capacidad para hacer más rentable el esfuerzo propio del estudiante, opera en ambos márgenes. El profesor que maximiza conocimiento no debe apuntar a castigar el uso de IA, sino a motivar el estudio.

1. Contexto e introducción

La irrupción de la inteligencia artificial generativa ha alterado de manera estructural la economía de la evaluación académica. Herramientas como Claude Code permiten producir entregables de alta calidad a costo casi nulo, lo que rompe la correspondencia tradicional entre output entregado y conocimiento adquirido.¹ La literatura empírica ha documentado tanto las capacidades técnicas de estos modelos para resolver evaluaciones estándar de economía (Geerling et al., 2023) como las preocupaciones de integridad académica derivadas de su uso masivo (Cotton et al., 2024). La respuesta natural del cuerpo docente ha sido el rediseño

*Facultad de Economía y Negocios, Universidad de Chile. Correo: joamartine@fen.uchile.cl.

¹Se reconoce el uso de la IA Agéntica en la misma elaboración de este documento.

de instrumentos de evaluación: Geerling et al. (2023) argumentan que los profesores deben adoptar formatos más resistentes a respuestas automatizadas, y Smith (2016) anticipó esta lógica al proponer exámenes orales individualizados como respuesta al cheating facilitado por internet.

La discusión, sin embargo, ha sido predominantemente policy oriented y carece de una formalización que permita derivar predicciones testeables sobre cuándo y por qué un mecanismo de monitoreo debiera implementarse. El problema es esencialmente uno de principal-agente con monitoreo costoso, una estructura cuya aplicación a contextos educativos tiene una tradición consolidada (Bishop and Wößmann, 2002; Kivistö, 2008). Más cerca del problema específico, Boleslavsky and Cotton (2015) analizan cómo una institución fija estándares de calificación para balancear selección e incentivos al esfuerzo, en un juego de Stackelberg donde el diseñador del mecanismo se mueve primero. La irrupción de la IA, sin embargo, agrega una dimensión nueva: el estudiante ya no solo elige cuánto esfuerzo ejercer sino también cómo dividir la producción del entregable entre esfuerzo propio (que genera aprendizaje) y delegación a la IA (que no).

Este trabajo se ubica en esa brecha. Modelamos la interacción entre un profesor y un estudiante representativo como un juego secuencial de Stackelberg con solución cerrada. El profesor dispone de un mecanismo de monitoreo basado en presentaciones aleatorias en clase, donde se le pide al estudiante explicar bajo sus propias palabras la solución de la tarea. Esta dinámica induce al estudiante a esforzarse y a internalizar el contenido, pero es costosa en términos de tiempo de clase y carga de corrección. El estudiante, por su parte, puede sustituir esfuerzo propio por delegación a la IA, lo cual abarata la producción del entregable pero no genera aprendizaje. La principal contribución del modelo es distinguir formalmente dos canales por los cuales el monitoreo opera: un canal disuasivo, que castiga la delegación, y un canal pedagógico, que aumenta la productividad del esfuerzo propio. La conclusión normativa central es que el segundo domina al primero, y que el profesor que maximiza aprendizaje debe diseñar el monitoreo como dispositivo pedagógico antes que como castigo.

2. Setup del juego

Orden e información del juego. El juego es de información completa y se desarrolla en dos etapas, específicamente un Stackelberg con el profesor como líder.

1. El profesor elige el nivel de monitoreo $m \in [0, 1]$, interpretado como la probabilidad de que el estudiante sea llamado a presentar su tarea en clase.
2. Observado m , el estudiante elige simultáneamente esfuerzo propio $e \geq 0$ y delegación a la IA $a \geq 0$.

Por lo resolvemos por inducción hacia atrás para encontrar el equilibrio perfecto en subjuegos.

Jugadores

Estudiante. La nota depende del output total entregado que depende del esfuerzo y el trabajo delegado a la IA, $g(e, a) = e + a$. La aplicación de esfuerzo propio (e) genera conocimiento para el estudiante sin embargo, este no está internalizado. Adicionalmente el esfuerzo tiene un costo cuadrático que decrece en el monitoreo, capturando que la perspectiva de presentar orienta el trabajo hacia la comprensión y, por tanto, lo vuelve más productivo por unidad de costo. La delegación a la IA tiene un costo cuadrático con factor $\gamma \in (0, 1)$, reflejando que producir output vía IA es más barato que producirlo por cuenta propia. Adicionalmente, si el estudiante es llamado a presentar, la fracción delegada queda expuesta y genera una penalización lineal ϕa .

La utilidad del estudiante es:

$$U^S(e, a | m) = \alpha(e + a) - m\phi a - \frac{e^2}{2(1 + \delta m)} - \frac{\gamma}{2}a^2, \quad (1)$$

con $\alpha > 0$ la valoración de la nota, $\phi > 0$ la severidad de la exposición pública, $\delta > 0$ la elasticidad del costo de esfuerzo al monitoreo y $\gamma \in (0, 1)$ el costo relativo de delegar. Este δ es sumamente relevante para la efectividad del mecanismo, este parámetro depende de la calidad del mecanismo en demostrar conocimiento.²

Profesor. El conocimiento adquirido por el estudiante depende exclusivamente del esfuerzo propio, $K = f(e)$. Para obtener forma cerrada asumimos $f(e) = e$. El profesor enfrenta además un costo cuadrático de monitorear, asociado a la pérdida de tiempo de clase y al mayor esfuerzo de corrección:

$$C(m) = \frac{\kappa}{2}m^2, \quad \kappa > 0. \quad (2)$$

La utilidad del profesor es:

$$U^P(m) = f(e^*(m)) - \frac{\kappa}{2}m^2, \quad (3)$$

donde $e^*(m)$ es la mejor respuesta del estudiante.

²Que la presentación sea explicar tu razonamiento, en vez de leer tu respuesta en voz alta. Que la presentación exija conectar conceptos, en vez de seguir cronológicamente las distintas partes de la tarea.

3. Equilibrio

Etapla 2: problema del estudiante. Tomando m como dado, las condiciones de primer orden son:

$$\frac{\partial U^S}{\partial e} = \alpha - \frac{e}{1 + \delta m} = 0, \quad (4)$$

$$\frac{\partial U^S}{\partial a} = \alpha - m\phi - \gamma a = 0. \quad (5)$$

La primera CPO iguala el retorno marginal de esfuerzo propio en la nota (α) con su costo marginal, que decrece en m .

$$e^*(m) = \alpha(1 + \delta m) \quad (6)$$

cuanto más probable es la presentación (m), más productivo es estudiar y mayor es el esfuerzo óptimo, este mecanismo se amplifica por la elasticidad del costo de monitoreo al esfuerzo.

La segunda CPO iguala el retorno marginal neto de delegar (la nota α menos el costo esperado de quedar expuesto $m\phi$) con el costo marginal de delegación.

Despejando:

$$a^*(m) = \frac{\alpha - m\phi}{\gamma} \quad (7)$$

El monitoreo cumple un doble rol: aumenta el esfuerzo propio ($\partial e^*/\partial m > 0$) y reduce la delegación ($\partial a^*/\partial m < 0$). La solución interior para a^* requiere $m \leq \alpha/\phi$.




Figura 1. Mejores respuestas $e^*(m)$ y $a^*(m)$ en función del monitoreo.




Figura 2. Composición del output total $g^*(m) = e^*(m) + a^*(m)$.

Etapla 1: problema del profesor. Sustituyendo $e^*(m)$ en U^P :

$$U^P(m) = \alpha(1 + \delta m) - \frac{\kappa}{2}m^2. \quad (8)$$

La condición de primer orden es:

$$\frac{\partial U^P}{\partial m} = \alpha\delta - \kappa m = 0. \quad (9)$$

El profesor iguala el beneficio marginal de monitorear, que es el aumento marginal en el conocimiento del estudiante inducido por la presentación ($\alpha\delta$), con el costo marginal de la clase perdida (κm). La solución de equilibrio es:

$$m^* = \frac{\alpha\delta}{\kappa} \quad (10)$$

Predicciones. A partir de m^* se obtienen las siguientes predicciones:

$$\begin{aligned} \frac{\partial m^*}{\partial \alpha} &> 0 && \text{(estudiantes que valoran más la nota inducen más monitoreo),} \\ \frac{\partial m^*}{\partial \delta} &> 0 && \text{(mayor productividad del monitoreo conviene implementarlo más),} \\ \frac{\partial m^*}{\partial \kappa} &< 0 && \text{(mayor costo de oportunidad reduce el monitoreo óptimo).} \end{aligned}$$

En este modelo base, γ (costo de usar IA) no afecta m^* porque el profesor solo valora e y la tecnología de aprendizaje es lineal. Para que la difusión de la IA (caída de γ) modifique el monitoreo óptimo se requiere relajar uno de estos dos supuestos, lo que queda como extensión natural del modelo.

4. Implicancias prácticas: guía para un buen monitoreo

El modelo entrega una recomendación clara, el profesor que busca maximizar aprendizaje debe diseñar el monitoreo apuntando a aumentar δ (productividad pedagógica del mecanismo) y a reducir κ (costo de oportunidad del tiempo de clase), antes que a aumentar ϕ (severidad de la exposición). A continuación se sugieren vías concretas.

Vías para aumentar δ . El parámetro δ captura cuánto la perspectiva de presentar modifica la tecnología de estudio del estudiante, haciendo que el esfuerzo propio rinda más por unidad de costo. Algunas vías:

- Exigir explicación, no exposición.
- Preguntas conceptuales abiertas.
- Variar la pregunta presentada.
- Hacer del error un momento pedagógico.

- Pedir conexiones con clases previas.

Vías para reducir κ . El parámetro κ captura el costo de oportunidad de usar tiempo de clase para monitoreo. Algunas vías para bajarlo:

- Integrar la presentación al contenido.
- Presentaciones cortas y focalizadas.
- Usar presentaciones como repaso.
- Externalidades positivas hacia la audiencia.

5. Limitaciones del modelo

El modelo es deliberadamente parsimonioso para obtener una solución cerrada interpretable, lo que implica varios supuestos que vale la pena hacer explícitos.

Preferencias del estudiante. El estudiante en el modelo no valora directamente el conocimiento, solo le importa la nota neta de costos de esfuerzo y de exposición. Esto es claramente extremo. Una extensión natural sería incluir un término $\beta K = \beta e$ en la utilidad del estudiante, capturando que parte de la motivación de estudiar es aprender. Bajo ese supuesto, el esfuerzo propio sería mayor incluso sin monitoreo, y el rol del profesor sería menos crítico.

Tecnología de aprendizaje lineal. Asumimos $f(e) = e$, lo que implica rendimientos constantes del esfuerzo en aprendizaje. En la práctica es más razonable suponer rendimientos decrecientes ($f'' < 0$).

Estudiante representativo. En la realidad los cursos son heterogéneos en α y en habilidad. El monitoreo óptimo probablemente debería depender de la distribución de tipos, no de un agente promedio.

Estática. El modelo es de un solo período. Una extensión dinámica permitiría capturar efectos de reputación (el profesor que monitorea constantemente induce hábitos de estudio que persisten) y de aprendizaje del estudiante sobre la estrategia del profesor. En el fondo, la estrategia del estudiante puede cambiar si las presentaciones se hacen una vez al semestre o cada dos semanas.

Naturaleza de la IA. Tratamos la IA como una tecnología que abarata producir output sin generar aprendizaje. Esto ignora usos legítimos de la IA como herramienta de estudio (resolver dudas, explorar ejemplos, recibir retroalimentación), que podrían generar aprendizaje genuino. Una modelación más fina distinguiría entre delegación sustitutiva y uso complementario.

A. Extensión

El modelo base supone que la penalización por exposición pública es ϕa , es decir, proporcional a la cantidad delegada a la IA. Esto genera que ϕ no afecte el esfuerzo propio del estudiante en equilibrio, la severidad del monitoreo opera puramente como impuesto sobre a . Una especificación más realista reconoce que lo que el profesor castiga al hacer presentar no es la delegación en sí, sino el gap entre lo entregado y lo entendido. Si el estudiante entrega mucho output pero sabe poco, queda mal, pero si entrega lo mismo que sabe, no.

En esta extensión reemplazamos la penalización por:

$$\text{penalización} = \phi m(a - e), \quad (11)$$

de modo que la exposición castiga proporcionalmente al diferencial entre delegación y esfuerzo propio. Esta especificación introduce un canal motivacional adicional para ϕ , estudiar más reduce el castigo esperado. La utilidad del estudiante es ahora:

$$U^S(e, a | m) = \alpha(e + a) - \phi m(a - e) - \frac{e^2}{2(1 + \delta m)} - \frac{\gamma}{2}a^2. \quad (12)$$

Las condiciones de primer orden son:

$$\frac{\partial U^S}{\partial e} = \alpha + \phi m - \frac{e}{1 + \delta m} = 0, \quad (13)$$

$$\frac{\partial U^S}{\partial a} = \alpha - \phi m - \gamma a = 0. \quad (14)$$

La primera CPO iguala el retorno marginal de estudiar, que ahora incluye el alivio del castigo esperado ($\alpha + \phi m$), con el costo marginal de esfuerzo. La segunda CPO iguala el retorno marginal neto de delegar, reducido por el castigo esperado, con su costo marginal. La severidad ϕ ahora opera en ambos márgenes.

Despejando:

$$e^*(m) = (\alpha + \phi m)(1 + \delta m), \quad a^*(m) = \frac{\alpha - \phi m}{\gamma} \quad (15)$$

Manteniendo $f(e) = e$, la utilidad del profesor evaluada en la mejor respuesta del estudiante es:

$$U^P(m) = (\alpha + \phi m)(1 + \delta m) - \frac{\kappa}{2}m^2. \quad (16)$$

Expandiendo:

$$U^P(m) = \alpha + (\alpha\delta + \phi)m + \phi\delta m^2 - \frac{\kappa}{2}m^2. \quad (17)$$

La condición de primer orden es:

$$\alpha\delta + \phi + 2\phi\delta m - \kappa m = 0. \quad (18)$$

Para que el problema sea cóncavo y la solución interior sea un máximo se requiere $\kappa > 2\phi\delta$. Bajo este supuesto:

$$m^* = \frac{\alpha\delta + \phi}{\kappa - 2\phi\delta} \quad (19)$$

A diferencia del modelo base, ϕ ahora afecta el monitoreo óptimo. Sus efectos pueden derivarse directamente:

$$\begin{aligned} \frac{\partial m^*}{\partial \phi} &> 0 && \text{(la severidad aumenta el monitoreo óptimo),} \\ \frac{\partial m^*}{\partial \delta} &> 0 && \text{(la productividad pedagógica también).} \end{aligned}$$

La extensión preserva las predicciones del modelo base y agrega un canal por el cual la severidad importa. Sin embargo, la conclusión normativa central sobre el diseño del monitoreo se refuerza.

Referencias

John H. Bishop and Ludger Wößmann. Institutional effects in a simple model of educational production. Working paper, 2002.

Raphael Boleslavsky and Christopher Cotton. Grading standards and education quality. *American Economic Journal: Microeconomics*, 7(2):248–279, 2015.

Debby R. E. Cotton, Peter A. Cotton, and J. Reuben Shipway. Chatting and cheating: Ensuring academic integrity in the era of chatgpt. *Innovations in Education and Teaching International*, 61(2):228–239, 2024.

Wayne Geerling, G. Dirk Mateer, Jadrian Wooten, and Nikhil Damodaran. Chatgpt has aced the test of understanding in college economics: Now what? *The American Economist*, 68(2): 233–245, 2023.

Jussi Kivistö. An assessment of agency theory as a framework for the government–university relationship. *Journal of Higher Education Policy and Management*, 30(4):339–350, 2008.

Robert Smith. Why academic cheating is all about economics. Inside Higher Ed, 2016. <https://www.insidehighered.com/views/2016/03/08/why-academic-cheating-all-about-economics-essay>.